

腾讯开源 · MIT 协议 · v0.3.3

腾讯开源 WeKnora

你的本地私有 NotebookLM

比 IMA 更懂你的文档，比 RAGFlow 更好扩展的企业级 AI 知识库平台

GitHub: github.com/Tencent/WeKnora | 官网: weknora.weixin.qq.com

深度技术解析 · 部署指南 · 架构流程图

目录

▶ Part 1: 部署与使用 (50%)

- 1.1 什么是 WeKnora? 应用场景
- 1.2 五分钟本地部署
- 1.3 知识库配置与使用
- 1.4 Agent 模式使用
- 1.5 接入 MCP (Cursor / Claude Desktop)
- 1.6 开发者快速模式

▶ Part 2: 架构与核心流程 (50%)

- 2.1 整体系统架构图
- 2.2 RAG Pipeline 完整流程
- 2.3 ReAct Agent 执行流程
- 2.4 文档解析异步流程
- 2.5 MCP 双向集成架构
- 2.6 技术栈全景
- 2.7 数据模型设计

Part 1：部署与使用

1.1 WeKnora 是什么？

你有没有想过，有一天公司内部知识库可以像聊天一样被问答，复杂报告可以被 AI 代劳分析，连外部工具都能被 Agent 自动调用——而这一切，数据永不出内网？腾讯开源的 WeKnora，正在做这件事。

WeKnora 是腾讯开源的企业级文档理解与 AI 检索框架。如果你用过 Google 的 NotebookLM 或腾讯自家的 IMA，可以把 WeKnora 理解成可私有化部署、完全掌控数据、深度可定制的「本地版 NotebookLM」。

它的核心能力：上传你的文档，问它任何问题，Agent 会自主检索、推理、调用工具，直到给你一个有据可查的答案。

场景	具体用法	核心价值
 企业知识库问答	上传内部手册、规范文档，员工用自然语言查询	降低沟通成本，知识沉淀
 合同/法规分析	上传合同 PDF，提问关键条款，标注引用来源	提升合规效率
 数据分析报告	上传 CSV/Excel，Agent 自动写 SQL 分析并生成图表	替代初级分析师工作
 学术研究辅助	上传论文集，跨文档检索关联结论	加速文献综述
 产品技术支持	搭建产品手册知识库，对接客服系统	降低支持成本

1.2 五分钟本地部署

◆ 环境要求

必须安装


- Docker + Docker Compose
- Git
- 机器: 4 核 8G 起步


推荐配置


- 16G 内存 (含高精度 PDF 解析)
- GPU 可选 (本地模型推理)
- Ollama (本地模型服务)

◆ 部署流程图

图 1-1: WeKnora 本地部署流程







◆ 关键环境变量说明

```
# — 大模型配置 (支持 OpenAI 兼容接口) —————
LLM_BASE_URL=https://api.deepseek.com/v1      # 或 Qwen、本地 Ollama
LLM_API_KEY=sk-xxxxxxxxxxxxxxxxxxxxxxxxxx

# — Embedding 模型 (本地 Ollama 最省钱) —————
EMBEDDING_BASE_URL=http://localhost:11434
EMBEDDING_MODEL=nomic-embed-text             # 或 bge-m3



# — 数据库 (Docker Compose 已内置, 通常无需改动) —————
POSTGRES_DB=weknora
POSTGRES_USER=weknora
POSTGRES_PASSWORD=your_strong_password

# — 对象存储 (默认本地存储, 可选 MinIO/COS/TOS) —————
STORAGE_TYPE=local                           # local | minio | cos | tos
```

◆ Docker Compose 服务组成

图 1-2: Docker Compose 服务拓扑






1.3 知识库配置与使用

◆ 知识库操作流程

图 1-3：知识库创建与文档上传流程



◆ 支持的文档类型

类型	格式	解析引擎	特殊能力
PDF	.pdf	pdfplumber + MinerU (高精度模式)	表格、公式、多栏布局
Word	.docx / .doc	python-docx / LibreOffice	图片 OCR 提取
图片	.png / .jpg / .webp	PaddleOCR / VLM 视觉描述	文字识别 + 图片描述
表格	.xlsx / .csv	openpyxl / DuckDB	Data Analyst 模式
Markdown	.md	mistune	保留标题层级
网页	URL	ChromeDP + html2markdown	动态页面渲染

1.4 Agent 模式使用

WeKnora 提供两种对话模式，在输入框左侧可以切换：

⚡ 快速回答 (Quick Answer)

- 单次 RAG 检索，毫秒级响应
- 适合：明确的知识查询
- 适合：FAQ 问答
- 适合：简单信息检索

🧠 深度推理 (Smart Reasoning)

- ReAct 多轮工具调用（最多 20 轮）
- 适合：复杂多步骤推理
- 适合：跨文档综合分析
- 适合：数据分析 + 报告生成

◆ Agent 可用的内置工具


工具名	功能	典型使用场景
<code>knowledge_search</code>	语义向量检索知识库	根据问题语义找相关内容
<code>grep_chunks</code>	关键词精确匹配切片	精确查找特定术语、编号
<code>list_knowledge_chunks</code>	按 ID 读取完整切片内容	深度读取已定位的文档段落
<code>get_document_content</code>	获取文档全文	需要完整阅读某份文档
<code>query_knowledge_graph</code>	Neo4j 图谱关系查询	查询实体关联关系
<code>web_search</code>	网络搜索（需启用）	知识库不足时补充外网信息
<code>web_fetch</code>	抓取指定网页内容	获取特定 URL 页面
<code>todo_write</code>	创建/更新任务计划	多步任务分解与跟踪
<code>thinking</code>	链式思考记录	复杂推理中间过程可视化
<code>execute_skill</code>	执行 Skills 技能	调用外部沙箱脚本

◆ 自定义 Agent 配置

💡 在「Agent 管理」页面，你可以创建自定义 Agent，配置：模型选择、绑定知识库、允许使用的工具、最大迭代次数（默认 20）、是否开启反思机制、系统 Prompt 模板、RAG 检索阈值等。每个业务场景都可以有一套专属的 Agent 配置。

1.5 接入 MCP (Cursor / Claude Desktop)

图 1-4: WeKnora MCP 双向接入示意



◆ 配置 Claude Desktop / Cursor 调用 WeKnora

```
// claude_desktop_config.json 或 cursor mcp 配置
{
  "mcpServers": {
    "weknora": {
      "args": [
        "path/to/WeKnora/mcp-server/run_server.py"
      ],
      "command": "python",
      "env": {
        "WEKNORA_API_KEY": "sk-你的APIKey (在开发者工具请求头 x-api-key 中获取)",
        "WEKNORA_BASE_URL": "http://localhost:8080/api/v1"
      }
    }
  }
}
```

```
}  
}
```

配置完成后，你在 Cursor 里可以直接对话：「帮我从 WeKnora 知识库检索关于 XX 的内容」，AI 会自动调用 WeKnora 的检索工具。

也可以 pip 安装后直接使用：

```
pip install weknora-mcp-server  
python -m weknora-mcp-server
```

1.6 开发者快速模式


```
# 方法一：Make 命令（推荐）  
make dev-start      # 启动 PostgreSQL + Redis 等基础设施  
make dev-app        # 启动 Go 后端（Air 热重载，修改代码 5-10s 生效）  
make dev-frontend   # 启动前端（Vite HMR 即时热更新）  
  
# 方法二：一键启动  
./scripts/quick-dev.sh
```

- ✅ 前端修改：Vite HMR 即时生效，无需刷新
- ✅ 后端修改：Air 热重载，5-10 秒重启
- ✅ 无需重新 build Docker 镜像
- ✅ 支持 IDE 断点调试（Go delve）

Part 2: 架构与核心流程

2.1 整体系统架构


图 2-1: WeKnora 整体系统架构图



2.2 RAG Pipeline 完整流程

WeKnora 的 RAG 流程采用事件驱动的插件化责任链架构，每个阶段是独立插件，通过 `EventManager` 串联，支持灵活替换和扩展。

图 2-2: RAG Pipeline 完整数据流 (插件责任链)



👤 用户提问
『XXX是什么?』

插件1: PluginRewrite (查询重写)

获取最近 20 条历史消息

按 RequestID 分组 → 取最近5轮对话

LLM 重写

Temperature=0.3, MaxTokens=50

插件2: PluginSearch (混合检索·并发)

知识库检索细节

知识库检索 (并发多KB)

文档 ≤50块?

是

直接全量加载

Score=1.0

否

向量检索

HNSW余弦相似度

否

BM25关键词检索

中文lindera分词

RAG压缩→临时知识库

合并去重

按Score排序

网络搜索 (可选)

插件3: PluginRerank (重排序)

清洗Passage
去除Markdown/代码噪声

增强Passage
图片OCR + 生成问题


调用Rerank模型API

阈值过滤
自适应降级 (×0.7重试)

🔄 查询扩展 (可选)

召回量不足时LLM生成多变体查询
重新检索追加结果

追加



◆ 综合评分公式详解

权重	来源	说明
60%	Rerank 模型评分	语义相关性（最重要）
30%	基础检索评分	向量余弦/BM25 原始分
10%	来源权重	知识库(1.0) > 网络搜索(0.95)
×乘数	位置先验	文档前段内容轻微加分 ±5%

2.3 ReAct Agent 执行流程

图 2-3: ReAct Agent 完整执行时序图







图 2-4: Agent 工具选择决策流程




2.4 文档解析异步流程

图 2-5: 文档上传到向量化完整异步流程









◆ 父子切片架构 (v0.3.3 新增)

图 2-6: 父子切片层级结构与检索升级机制



2.5 MCP 双向集成架构

图 2-7: MCP 双向集成完整架构



 **安全设计：** WeKnora 已禁用 MCP Stdio 传输（防止命令注入攻击），仅允许 HTTP SSE 和 HTTP Streamable 传输。工具注册采用 first-wins 策略防止同名工具覆盖攻击。

图 2-8: WeKnora 完整技术栈



Syntax error in text
mermaid version 10.9.5

2.7 数据模型设计

图 2-9：核心数据库表关系图（ER 图）





图 2-10：多租户隔离与认证流程



总结

WeKnora 是一个工程完成度相当高的开源项目。从架构设计来看，有几点特别值得关注：

📁 架构设计亮点

- RAG Pipeline 插件化责任链，可灵活扩展阶段
- ReAct Agent 事件驱动，全程 SSE 流式推送
- 文档解析独立微服务，gRPC 解耦，可单独扩容
- MCP 双向集成，既对外暴露能力，又能调用外部工具
- halfvec + HNSW 向量存储，节省 50% 空间
- PostgreSQL 一库搞定向量+全文检索，减少依赖

✅ 适合的场景

- 数据不能出内网的企业知识库
- 需要深度定制 RAG 流程的研发团队
- 想用 MCP 扩展 AI 能力边界的项目
- 需要多租户隔离的 SaaS 平台
- 数据分析 + AI 问答一体化的场景

维度	WeKnora	RAGFlow	Dify
RAG 深度	★★★★★ 插件链+父子切片+MMR	★★★★★	★★★★★
Agent 能力	★★★★★ ReAct+工具+反思	★★★	★★★★★
MCP 集成	★★★★★ 双向集成	★★	★★★★★
部署难度	★★★ Docker一键	★★★	★★★
二次开发	★★★★★ Go+Vue标准栈	★★★	★★★★★
开源协议	MIT（完全开源）	Apache 2.0	Apache 2.0

🌟 项目地址: github.com/Tencent/WeKnora | 官网: weknora.weixin.qq.com | 协议: MIT License