

腾讯开源 · MIT License · v0.3.3

腾讯开源 WeKnora

你的开源版 IMA

私有化部署的企业级 AI 知识库平台

RAG 检索增强生成 · ReAct Agent · MCP 工具集成 · Skills 沙箱执行

GitHub: <https://github.com/Tencent/WeKnora> | 官网: <https://weknora.weixin.qq.com>

目录

- **Part 1: 部署与使用**
 - 1.1 WeKnora 是什么?
 - 1.2 快速部署
 - 1.3 支持的文档类型
 - 1.4 Agent 模式介绍
 - 1.5 接入 MCP
 - 1.6 上手操作案例演示
- **Part 2: 架构与核心流程**
 - 2.1 整体系统架构
 - 2.2 RAG Pipeline 流程
 - 2.3 ReAct Agent 执行流程
 - 2.4 文档解析与向量化流程
 - 2.5 记忆系统 (Memory)
 - 2.6 Skills + Sandbox 扩展能力
 - 2.7 Agent Loop 完整执行流程
- **结语: WeKnora 与 OpenClaw 的能力对齐**

WeKnora 实现了 OpenClaw 定义的三大 Agent 核心能力

OpenClaw（开放爪子框架）定义现代 AI Agent 必须具备三个基本维度：**Memory（记忆）**、**Skills + Sandbox（能力扩展 + 安全执行）**、**Agent Loop（循环推理）**。WeKnora 对这三者均有完整实现：



Memory（记忆）

多轮对话上下文管理
滑动窗口 + LLM 摘要压缩
跨会话持久化存储
Episode + 知识图谱实体记忆



Skills + Sandbox

SKILL.md 渐进式技能加载
Python/JS/Shell 脚本执行
Docker 容器隔离沙箱
多层安全校验体系



Agent Loop

ReAct 推理-行动循环
最多 20 轮迭代
EventBus 驱动流式推送
工具并发调用 + 反思机制

Part 1：部署与使用

五分钟启动，零代码搭建你的私有 AI 知识库

1.1 WeKnora 是什么？

如果你用过腾讯的 IMA，WeKnora 可以理解成它的开源、可私有化部署版本。数据完全在自己手里，模型可以选本地也可以接云端，整个系统跑在你自己的服务器上。

WeKnora 是腾讯开源的企业级 AI 知识库框架，核心是 **RAG（检索增强生成）**——上传你的文档，用自然语言提问，系统从文档里精准检索后交给大模型生成答案。Agent 模式下还能多步推理、调用工具，完成更复杂的分析任务。

场景	用法
企业内部知识库	上传手册、规范文档，员工自然语言查询，给出有引用来源的答案
合同 / 法规分析	上传 PDF，提问关键条款，精确定位到原文段落
数据分析报告	上传 Excel / CSV，Agent 自动分析并生成结论报告
学术研究辅助	上传论文集，跨文档检索关联结论
产品技术支持	搭建产品文档知识库，替代初级客服问答

1.2 快速部署

只需 Docker + Git，三步启动：

```
# 1. 克隆仓库
git clone https://github.com/Tencent/WeKnora.git
cd WeKnora

# 2. 复制并编辑环境变量
cp .env.example .env
# 在 .env 中填写 LLM API Key 或指向本地 Ollama 地址

# 3. 启动服务
docker compose up -d                                # 最小核心服务
# 或
docker-compose --profile full up -d                  # 全功能（含 Neo4j 知识图谱等）
```

启动后访问 `http://localhost`，注册账号，进入初始化向导配置模型即可。

服务	说明	端口
----	----	----

Web UI + 后端	Go 后端 + Vue 前端 (Nginx 托管)	:80 / :8080
PostgreSQL	主数据库 (含向量扩展 + BM25 全文检索)	:5432
Redis	异步任务队列 + 缓存	:6379
docreader	Python 文档解析微服务 (gRPC)	:50051
Neo4j (可选)	知识图谱存储	:7474
MinIO (可选)	对象存储	:9000

 **开发者模式：**`make dev-start` 启动基础设施, `make dev-app` 启动后端 (Air 热重载), `make dev-frontend` 启动前端 (Vite HMR)。

1.3 支持的文档类型

格式	解析引擎	特殊能力
PDF	pdfplumber / MinerU (高精度)	表格、公式、多栏版面还原
Word (.docx / .doc)	python-docx / LibreOffice	图片 OCR 文字提取
图片 (.png / .jpg)	PaddleOCR + VLM 视觉描述	文字识别 + 图片语义理解
Excel / CSV	openpyxl / DuckDB	数据分析 Agent 模式
Markdown	mistune	保留标题层级结构
网页 URL	ChromeDP + html2markdown	动态页面渲染抓取

1.4 Agent 模式介绍

WeKnora 提供两种对话模式，在输入框左下角切换：

模式	说明	适合场景
 快速回答	单次 RAG 检索，快速响应	明确知识点查询、FAQ 查询
 深度推理 (Agent)	ReAct 多轮工具调用，最多 20 轮	跨文档分析、数据报告生成

Agent 可调用的内置工具包括：知识库语义检索、关键词精确匹配、文档全文读取、知识图谱查询、网络搜索、网页抓取、任务计划管理、Skills 脚本执行等，整个推理过程在前端实时可见。

1.5 接入 MCP

WeKnora 内置 MCP Server (Python), 可让 Cursor、Claude Desktop 等工具直接调用 WeKnora 的知识库检索能力:

```
{
  "mcpServers": {
    "weknora": {
      "command": "python",
      "args": ["path/to/WeKnora/mcp-server/run_server.py"],
      "env": {
        "WEKNORA_API_KEY": "sk-你的APIKey",
        "WEKNORA_BASE_URL": "http://localhost:8080/api/v1"
      }
    }
  }
}
```

反过来, WeKnora 的 Agent 也可以主动连接外部 MCP 服务(文件系统、数据库、自定义工具), 在 Agent 管理页面配置即可。安全起见, 只支持 HTTP SSE 和 HTTP Streamable 传输。

1.6 上手操作案例演示

下面以完整使用链路为例, 展示从零开始到用 Agent 完成知识库问答的全过程。

1

配置模型

首次进入系统会自动跳转初始化向导。依次配置 LLM 大语言模型(支持 Ollama 本地模型或 DeepSeek / Qwen 等远程 API)、Embedding 嵌入模型、Rerank 重排序模型。

WeKnora 系统初始化配置

首次使用需要配置模型和服务信息，完成后即可开始使用系统

配置导航

Ollama 服务

LLM 模型

Embedding 模型

Rerank 配置

多模态配置

文档分割

完成配置

Ollama 服务状态 正常 (0.11.8)

Ollama 服务地址 http://host.docker.internal:11434

已安装 gemma3:1b qwen2.5:7b qwen3:4b qwen2.5vl:3b qwen3:0.6b nomic-embed-text:latest qwen3:8b bge-large:latest qwen2.5:0.5b

模型 avil/UI-TARS:latest qwq:latest qwen2.5:7b-instruct-fp16

LLM 大语言模型配置

模型来源 ☐ Ollama (本地) ☒ Remote API (远程)

* 模型名称 deepseek-chat

* Base URL https://api.deepseek.com/v1

API Key (可选)

Embedding 嵌入模型配置

知识库中已有文件，无法修改Embedding模型配置

模型来源 ☒ Ollama (本地) ☐ Remote API (远程)

* 模型名称 nomic-embed-text:latest

* 维度 768 检测维度

图 1：系统初始化 — 配置 LLM 模型（此处以 DeepSeek 远程 API + Ollama 本地 Embedding 为例）

2

创建知识库

在知识库页面点击「新建知识库」，选择类型（文档型或 FAQ 型），填写名称与描述。文档型适合上传 PDF、Word 等文件；FAQ 型适合维护结构化问答对。

WEKNORA

快捷操作

+ 新建知识库

知识库

对话

近7天

WeKnora介绍

知识库

管理和组织您的知识库，支持文档型和问答型知识库

test

无描述

问答 (4)

2025-11-24 00:45:30

wizard

无描述

文档 (0)

2025-11-13 21:23:43

图片测试

222

文档 (54)

2025-11-20 17:10:34

图 2：知识库管理页面 — 可创建多个不同类型的知识库，支持文档型和问答型

3

上传文档

进入知识库详情页，拖拽或点击上传文档。系统异步解析（PDF / DOCX / 图片等），切片后向量化入库。支持批量上传、URL 导入。解析完成后状态变为「已完成」即可检索。



图 3：文档上传页面 — 支持 DOC、DOCX、PDF 等多种格式，系统自动解析并建立向量索引

4

切换 Agent 模式提问

新建对话，在输入框左下角点击「Agent 模式」，选择绑定知识库，发送问题。Agent 自动进行多步推理：关键词检索 → 语义检索 → 深度读取 → 生成有引用来源的答案。整个推理链路实时展示。

检索知识库 1 次、思考 4 次，调用工具 grep_chunks、查看知识分块

我来帮您查找2025年热门游戏推荐的相关信息。让我先分析一下这个问题，然后搜索知识库中的相关内容。

💡 深度思考

用户询问2025年热门游戏推荐，这是一个比较具体的查询。我需要搜索知识库中是否有相关的游戏推荐信息。从知识库概览中我看到有一个名为"test"的知识库包含游戏相关的文档，特别是"WKcCvkq8mu_近期热门游戏推荐.md"这个文件，看起来很有可能是相关的。让我先搜索这个知识库，看看是否有2025年游戏推荐的具体内容。

📖 调用 文本模式搜索：「2025,游戏,热门,推荐」

找到 27 处匹配（显示 11 个）

太好了！我在知识库中找到了专门关于2025年热门游戏推荐的文档。让我使用语义搜索来获取更详细的内容。

📖 检索知识库：「2025年热门游戏推荐，PC平台热门游戏，主机平台热门游戏，移动端热门游戏，2025年游戏市场趋...

找到 6 个结果，来自 2 个文件

现在让我获取完整的游戏推荐内容，以便为您提供详细的2025年热门游戏推荐。

📄 查看 WKcCvkq8mu_近期热门游戏推荐.md 的 23/23 个分块

根据知识库中的信息，我为您整理了2025年热门游戏推荐，涵盖PC、主机和移动端三大平台：

🎮 2025年热门游戏推荐

一、PC平台热门游戏

游戏名称	类型	推荐理由
博德之门3	RPG	深度剧情与自由度极高，口碑与玩家评价持续领先
Disco Elysium: The Final Cut	叙事冒险	独特的对话系统与哲学思考，适合喜欢故事驱动的玩家
光与影：33号远征队	独立/策略	虚幻5引擎打造，叙事创新，获TGA年度最佳候选
逃离鸭科夫	生存射击	战术性强、氛围紧张，硬核玩家首选

二、主机平台热门游戏

游戏名称	类型	推荐理由
GTA6	开放世界	2025年秋季发售，全球关注度极高，预告片创吉尼斯纪录
咚奇刚：焦力全开	平台动作	任天堂经典IP新作，关卡设计与趣味性提升
超级马里奥银河1+2	平台动作	Switch2新作，画面与玩法升级，适合各年龄层玩家
宝可梦传说：Z-A	RPG	全新开放世界探索，宝可梦系列创新力作
艾尔登法环：褪色者版	动作RPG	豪华+DLC+独占内容，战斗与探索体验出色
死亡搁浅2	动作冒险	创新叙事与玩法，剧情深度受玩家好评

三、移动端热门游戏

游戏名称	类型	推荐理由
王者荣耀	MOBA	持续霸榜，适合竞技与休闲玩家
原神	开放世界RPG	跨平台体验，剧情与探索丰富，全球热度高
鸣潮	动作RPG	画面精美，战斗流畅，国产新秀
命运：群星	SLG	策略深度与全球化运营表现优异

SD高达 G世代 永恒	收集策略	高达IP衍生，收集养成乐趣丰富
MONOPOLY GO!	休闲策略	轻松上手，全球玩家活跃
Last War: Survival / Whiteout Survival	生存SLG	末日题材，策略与资源管理兼备

📈 2025年游戏市场趋势

创新与趋势推荐

- 独立游戏爆发：如《光与影：33号远征队》，小团队也能实现高品质与创新玩法
- 二次元与IP衍生：如《数码宝贝物语 时空异客》《魔法少女的魔女审判》
- 搬砖与挂机手游：如《缔造者：放逐之地》《尤弥尔传奇》，适合碎片化娱乐

国产新作与出海表现

• 腾讯、网易、米哈游等大厂新作不断，如《王者荣耀：荣耀之章》《梦幻西游：灵山》《原神：尘歌壶》《崩坏：星穹铁道》《阴阳师：百闻牌》

基于知识库提问

 Agent 模式 ▾



 @ 知识库(2) ▾

T2 ✕

test ✕

deepseek-v3.1-terminus ▾



图 4：Agent 模式推理过程 — 可看到完整的思考步骤、工具调用过程和检索到的知识片段

5 查看答案与引用来源

Agent 输出带结构的 Markdown 答案，每个关键结论都标注了来源（来自哪个文档的哪个段落）。可点击引用标记跳转查看原文。

知识库



对话

• 春节饮食习俗



春节习俗

系统设置

参考了1个相关内容



已深度思考



春节期间，大家通常会吃以下几种食物：

1. 年糕：寓意万事如意年年高。年糕的种类有：

- 北方：白糕饯、黄米糕
- 江南：水磨年糕
- 西南：糯粑粑
- 台湾：红龟糕



2. 饺子：北方年夜饭的传统食物，形状像元宝，象征生活富裕和福运。吃饺子的习俗因地区而异，有的地方除夕之夜吃，有的地方初一吃，北方一些山区还有初一到初五每天早上吃饺子的习俗。



3. 元宵：南方称为“汤圆”，在江苏、上海等地，大年初一早晨都有吃汤圆的习俗。元宵节，道教称之为“上元节”。



基于知识库提问

3个来源




图 5：回答展示 — 基于知识库内容生成结构化答案，自动标注引用来源，支持图片内容展示

Part 2：架构与核心流程

多语言微服务架构 + 事件驱动设计，每个模块职责清晰、可扩展


2.1 整体系统架构

WeKnora 采用多语言微服务架构：Go 后端负责业务逻辑和 API，Python 微服务负责文档解析，Vue 3 前端负责交互展示，三者通过 HTTP/SSE 和 gRPC 协作。



2.2 RAG Pipeline 流程


WeKnora 的 RAG 流程是一条事件驱动的插件责任链，5 个插件依次处理，每个插件职责清晰、可替换：



设计	说明
父子切片架构	检索命中子切片时自动升级为父切片，获取更完整的上下文内容
halfvec 向量存储	使用 FP16 半精度存储向量，比 FP32 节省 50% 存储空间
综合评分公式	$0.6 \times \text{Rerank 分} + 0.3 \times \text{检索原始分} + 0.1 \times \text{来源权重}$
自适应降级	Rerank 阈值过高无结果时，自动 $\times 0.7$ 降级重试，保证有答案返回


2.3 ReAct Agent 执行流程

Agent 采用 **ReAct (Reason + Act)** 范式，LLM 自主决策每一步调用哪个工具，直到得出最终答案。整个过程通过 SSE 实时推流给前端展示。



Agent 的系统提示词强制执行「侦察-计划-执行」 workflow：先用关键词检索定位，再用语义检索扩展，再深度读取文档，最后才生成答案。禁止 LLM 凭内部知识直接回答，确保所有结论都来自知识库。


2.4 文档解析与向量化流程



父子切片设计：文档切片分两层，大段落作为父切片，句子或小段作为子切片。向量检索命中子切片时，系统自动返回对应父切片的完整内容——既保证检索精度，又保证上下文完整性。

2.5 记忆系统（Memory）


WeKnora 的 Memory 实现对应 OpenClaw 中的记忆层，分为短期记忆（上下文窗口）和长期记忆（Episode + 知识图谱）两个层次：



记忆层	机制	作用
上下文滑动窗口	保留最近 N 条消息，超出丢弃最老的	轻量多轮对话，低 Token 消耗
LLM 智能摘要	超过阈值时，LLM 自动摘要旧消息合并为 Summary	长对话不丢失关键信息
Episode 摘要记忆	每轮对话结束后生成摘要存入 DB，下次检索相关片段注入上下文	跨会话记忆用户信息和偏好

2.6 Skills + Sandbox 扩展能力


Skills 是 WeKnora 的能力扩展机制，对应 OpenClaw 中的 Skills 层。每个 Skill 是一个目录，包含 `SKILL.md` 定义文件和可执行脚本，Agent 可以按需加载并在沙箱中安全执行。



安全层	保护内容
脚本内容验证	检测 rm -rf、Fork Bomb、反弹 Shell、代码注入等危险模式
参数注入检查	检测 Shell 操作符、命令替换、路径遍历
Docker 容器隔离	内存/CPU 限制、网络禁用、只读根文件系统
命令白名单	仅允许 python/node/bash/cat/grep 等安全命令
路径安全验证	禁止访问 Skill 目录外的文件（防路径遍历）

2.7 Agent Loop 完整执行流程

这是将 Memory、Skills、RAG、MCP 整合在一起的完整 Agent 循环——也是 WeKnora 实现 OpenClaw Agent Loop 的核心设计：



结语：WeKnora 与 OpenClaw 的能力对齐

一个完整的开源 AI Agent 知识库平台

WeKnora 不只是一个 RAG 工具，它是一个完整的 AI Agent 知识库平台。回顾 OpenClaw 对现代 AI Agent 的三个核心能力要求，WeKnora 的实现情况如下：

OpenClaw 能力	WeKnora 实现	特点
 Memory (记忆)	ContextManager 多轮上下文 + Episode 摘要记忆 + 知识图谱 实体记忆	短期 + 长期双层，智能压缩不丢信息
 Skills + Sandbox	SKILL.md 渐进式加载 + Docker 沙箱执行 + 多层安全验证	可扩展能力包，安全隔离执行，零风险
 Agent Loop	ReAct 循环 + EventBus 事件驱动 + 最多 20 轮迭代 + 工具并发调用	全链路实时可观测，前端步骤树展示

与 IMA 相比，WeKnora 的优势在于**完全开源、数据自主、高度可定制**。IMA 是更成熟的产品，用户体验更完善；WeKnora 则是给技术团队的底层框架，你可以修改任何一个模块，接入任何模型，部署在任何环境。

适合 WeKnora 的场景：企业私有化部署、数据合规要求严格、需要深度定制 RAG 流程、希望集成内部工具（通过 MCP / Skills）、希望基于此二次开发自己的 AI 产品。

推荐使用链路：Docker 一键部署 → 配置本地 Ollama 模型（无 API 成本）→ 上传企业文档 → 用内置数据分析师 Agent 跑第一个分析任务 → 按需扩展 Skills 和 MCP 工具。

WeKnora · 腾讯开源 · MIT License

GitHub: <https://github.com/Tencent/WeKnora> | 官网: <https://weknora.weixin.qq.com>

本文基于 WeKnora v0.3.3 撰写